

Задание 1: Induction Heads DIY

1 Решение

$$W_E = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \end{pmatrix} \in \mathbb{R}^{3 \times 7}, \quad W_U = W_E^\top \in \mathbb{R}^{7 \times 3}$$

$$W_Q^{(1)} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix} \in \mathbb{R}^{7 \times 3}, \quad W_K^{(1)} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 5 & 0 & 0 \end{pmatrix} \in \mathbb{R}^{7 \times 3}$$

$$W_V^{(1)} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \in \mathbb{R}^{7 \times 3}$$

$$W_O^{(1)} = \begin{pmatrix} 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 \end{pmatrix} \in \mathbb{R}^{3 \times 7}$$

$$W_Q^{(2)} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \in \mathbb{R}^{7 \times 3}, \quad W_K^{(2)} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 5 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 5 \\ 0 & 0 & 0 \end{pmatrix} \in \mathbb{R}^{7 \times 3}$$

$$W_V^{(2)} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \in \mathbb{R}^{7 \times 3}$$

$$W_O^{(2)} = \begin{pmatrix} 5 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 5 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 5 & 0 & 0 & 0 & 0 \end{pmatrix} \in \mathbb{R}^{3 \times 7}$$

В коде видно, что вероятности получения верных предсказаний > 0.95 . Таким образом, понижая температуру softmax, понижая относительную норму старого токена в skip connections (повышая норму добавляемой части), мы добиваемся требуемого.

Первый слой действует следующим образом. Он берет взвешенное среднее предыдущих токенов (их эмбедингов), с коэффициентами, экспоненциально затухающими с удалением от текущего токена. То есть W_Q учитывает только позицию рассматриваемого токена (как единственную доступную «константу»), а W_K – только позицию предыдущего токена. Чем ближе к нам предыдущий токен, тем больше его позиционное кодирование по величине и тем больший вес он имеет. Таким образом, мы воспользовались позиционными эмбедингами, чтобы реализовать конкретную логическую операцию, пусть и создали этим такую проблему, что по факту учитывается не только предыдущий токен, но и остальные с меньшим весом.

(Минус логарифм основания экспоненты в softmax оказывается тем выше, чем больше индекс текущего токена ($\propto e^{pos}$). Вероятно, это не очень хороший эффект, и он следует из нашего кодирования позиций. Но в условно компах решать эту штуку очевидно не хочется)

После этого первый слой прибавляет эти эмбединги к текущему токenu, но со сдвигом: координату 1 к координате 4, 2 к 5, 3 к 6. Матрица $W_V^{(1)}W_O^{(1)}$ является матрицей такого сдвига трех координат, с занулением остальных, а механизм прибавления с весами реализуется в блоке $A \cdot X(W_VW_O)$ в Attention.

Таким образом, при достаточно большом основании экспоненты, в каждом токене (эмбединге) оказывается дополнительно записано содержание предыдущего токена в координатах 4-6.

Второй слой рассмотрим в контексте последнего токена. Слой оставляет от него one-hot кодирование буквы в Query, а от предыдущих токенов – one-hot кодирование предыдущей буквы в Key, на соответствующих индексах. Таким образом, слой находит все такие токены, перед которыми стоял тот токен, который является также последним в тексте.

Далее второй слой «предсказывает» токен, являющийся усреднением найденных токенов. Матрица $W_V^{(2)}W_O^{(2)}$ оказывается еще проще.

$W_K^{(1)}$ домножается на $C = 5$, чтобы повысить минус логарифм основания экспоненциального затухания.

$W_K^{(2)}$ домножается на $C = 5$, чтобы понизить приоритет токенов, перед которыми шел не тот токен, который является финальным.

$W_O^{(2)}$ домножается на $C = 5$, чтобы уменьшить влияние текущего токена на следующий токен, возникающее в результате skip connection.

Есть ощущение, что нам не нужен более высокий ранг W_VW_O нигде, так как нет способа даже исключить одно из умножений на константу для получения $\lim$ вероятности правильного токена $= 1$.

2 Пример: последовательность А, В, А

Входная матрица эмбедингов:

$$X = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 & 0 & 2 \\ 1 & 0 & 0 & 0 & 0 & 0 & 3 \end{pmatrix}$$

Слой 1 (previous-token head)

$$Q^{(1)} = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 0 & 0 \\ 3 & 0 & 0 \end{pmatrix}, \quad K^{(1)} = \begin{pmatrix} 5 & 0 & 0 \\ 10 & 0 & 0 \\ 15 & 0 & 0 \end{pmatrix}$$

$$\text{scores} = \frac{Q^{(1)}K^{(1)\top}}{\sqrt{d_h}} = \begin{pmatrix} 2.887 & 5.774 & 8.660 \\ 5.774 & 11.547 & 17.321 \\ 8.660 & 17.321 & 25.981 \end{pmatrix}$$

$$A^{(1)} = \text{softmax}_{\text{causal}}(\text{scores}) = \begin{pmatrix} 0 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}, \quad V^{(1)} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix}$$

$$\text{head_out}^{(1)} = A^{(1)}V^{(1)} = \begin{pmatrix} 0 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}, \quad \text{projected}^{(1)} = \text{head_out}^{(1)}W_O^{(1)} = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix}$$

$$X^{(1)} = X + \text{projected}^{(1)} = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 & 0 & 2 \\ 1 & 0 & 0 & 0 & 1 & 0 & 3 \end{pmatrix}$$

Слой 2 (induction head)

$$Q^{(2)} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix}, \quad K^{(2)} = \begin{pmatrix} 0 & 0 & 0 \\ 5 & 0 & 0 \\ 0.001 & 4.999 & 0 \end{pmatrix}$$

$$\text{scores} = \frac{Q^{(2)}K^{(2)\top}}{\sqrt{d_h}} = \begin{pmatrix} 0 & 2.887 & 0.001 \\ 0 & 0 & 2.886 \\ 0 & 2.887 & 0.001 \end{pmatrix}$$

$$A^{(2)} = \text{softmax}_{\text{causal}}(\text{scores}) = \begin{pmatrix} 0 & 0 & 0 \\ 1 & 0 & 0 \\ 0.053 & 0.947 & 0 \end{pmatrix}, \quad V^{(2)} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix}$$

$$\text{head_out}^{(2)} = A^{(2)}V^{(2)} = \begin{pmatrix} 0 & 0 & 0 \\ 1 & 0 & 0 \\ 0.053 & 0.947 & 0 \end{pmatrix}$$

$$\text{projected}^{(2)} = \text{head_out}^{(2)}W_O^{(2)} = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 5 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0.264 & 4.736 & 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

$$X^{(2)} = X^{(1)} + \text{projected}^{(2)} = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 5 & 1 & 0 & 1 & 0 & 0 & 2 \\ 1.264 & 4.736 & 0 & 0 & 1 & 0 & 3 \end{pmatrix}$$

Логиты последней позиции:

$$\ell = X_3^{(2)} \cdot W_U = (1.264 \quad 4.736 \quad 0)$$

$$p = \text{softmax}(\ell) = (P(A) \approx 0.030 \quad P(B) \approx 0.962 \quad P(C) \approx 0.008)$$